

Análise de impacto dos vídeos de saúde e bem estar

Ana Clara Melo Senne¹
Carolina Toledo Ferraz^{1,2}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil
²Programa de pós-graduação em Computação Aplicada (se houver)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

<10389744@mackenzista.com.br>

<carolina.ferraz@mackenzie.br>

2025

Palavras-chave: Inteligência Artificial; Processamento de Linguagem Natural; Análise de Sentimentos; Saúde Mental; YouTube; BERTimbau.

Keywords: Artificial Intelligence; Natural Language Processing; Sentiment Analysis; Mental Health; YouTube; BERTimbau

1. Introdução

1.1) Contextualização do problema de pesquisa

A crescente presença de conteúdos digitais sobre saúde e bem-estar nas plataformas de vídeo, especialmente no YouTube, tem provocado mudanças significativas na forma como as pessoas buscam e recebem informações sobre saúde mental e qualidade de vida. O consumo de vídeos que abordam temas como ansiedade, depressão, autocuidado e equilíbrio emocional aumentou expressivamente nos últimos anos, tornando o YouTube um espaço de troca e influência emocional. No entanto, essa popularização também traz desafios, pois parte dos conteúdos sobre saúde mental é produzida por pessoas sem formação técnica, o que pode gerar interpretações equivocadas, reforçar estigmas ou induzir comportamentos inadequados.

Nesse cenário, compreender como o público reage emocionalmente a esse tipo de conteúdo torna-se essencial. Comentários postados pelos usuários constituem um registro espontâneo de percepções e emoções, funcionando como indicadores de como determinados vídeos impactam a audiência. Contudo, o grande volume de comentários torna inviável uma análise manual, o que justifica o uso de abordagens automatizadas baseadas em Inteligência

Artificial (IA) e Processamento de Linguagem Natural (NLP). Essas técnicas permitem extrair e interpretar padrões de sentimento (positivos e negativos) presentes nas interações digitais, oferecendo um meio eficiente para avaliar o impacto emocional de conteúdos sobre saúde mental.

1.2) Definição e delimitação do problema de pesquisa

O problema central deste estudo consiste em compreender de que forma os vídeos sobre saúde mental e bem-estar disponíveis no YouTube influenciam emocionalmente seus espectadores. Embora existam avanços relevantes em análise de sentimentos e aprendizado de máquina, grande parte das pesquisas ainda se concentra em textos escritos em inglês e em contextos formais, como artigos, resenhas e redes profissionais. Isso cria uma lacuna significativa quanto à aplicação dessas técnicas a textos em português brasileiro, especialmente quando se trata de comentários informais e espontâneos produzidos em plataformas digitais.

Desse modo, o presente trabalho delimita-se à análise de comentários em língua portuguesa extraídos do YouTube, relacionados a vídeos sobre saúde mental e bem-estar. O estudo busca identificar, por meio de um modelo de aprendizado supervisionado, se os sentimentos expressos nos comentários indicam reações predominantemente positivas ou negativas diante do conteúdo assistido. Essa delimitação permite compreender de forma mais precisa o impacto emocional e social dos vídeos voltados à saúde e ao autocuidado mental na comunidade brasileira online.

1.3) Objetivos Geral e Específicos da pesquisa

O objetivo geral desta pesquisa é desenvolver um modelo de classificação capaz de analisar o impacto emocional de vídeos do YouTube relacionados à saúde e bem-estar, com ênfase em saúde mental, identificando se o conteúdo desperta reações predominantemente positivas ou negativas entre os espectadores. A proposta busca compreender de que forma os comentários expressos pelos usuários refletem o efeito emocional causado pelos vídeos, contribuindo para uma visão mais ampla sobre como conteúdos digitais podem influenciar percepções, sentimentos e comportamentos associados ao autocuidado e à conscientização sobre saúde mental.

De forma complementar ao objetivo geral, a pesquisa busca atingir os seguintes objetivos específicos:

- Identificar como os temas relacionados à saúde mental e bem-estar são abordados em vídeos publicados no YouTube;
- Analisar os sentimentos e reações expressos pelos usuários nos comentários desses vídeos, considerando suas polaridades (positiva ou negativa).
- Avaliar o desempenho do modelo *BERTimbau* na tarefa de geração de *embeddings* para a língua portuguesa.
- Investigar de que forma os conteúdos audiovisuais influenciam as percepções e interações das comunidades digitais relacionadas à saúde mental.

1.4) Contribuições da pesquisa para a academia e sociedade

A relevância desta pesquisa manifesta-se em duas dimensões complementares: acadêmica e social.

Do ponto de vista acadêmico, o estudo amplia a aplicação de técnicas de Processamento de Linguagem Natural e aprendizado profundo à língua portuguesa, em um contexto ainda pouco explorado, o das interações informais em plataformas de vídeo. A utilização do modelo *BERTimbau* representa um avanço técnico relevante, ao adaptar abordagens de ponta para o português e demonstrar seu potencial na interpretação de sentimentos e emoções em textos espontâneos. Assim, a pesquisa contribui para o estado da arte na área de NLP aplicada à análise de sentimentos, servindo de referência para investigações futuras em ambientes digitais.

No aspecto social, a pesquisa propõe uma ferramenta capaz de identificar como o consumo de conteúdos sobre saúde mental afeta emocionalmente o público, fornecendo insumos para profissionais da saúde, comunicadores e plataformas digitais desenvolverem estratégias mais responsáveis de divulgação e mediação de informação. Ao permitir uma leitura automatizada das reações emocionais dos espectadores, o estudo contribui para o fortalecimento de práticas comunicacionais que valorizem o bem-estar psicológico, a empatia e a disseminação de conteúdos confiáveis sobre saúde mental.

2. Referencial Teórico

2.1) Inteligência Artificial e Aprendizado de Máquina

A Inteligência Artificial (IA) é o campo da ciência da computação dedicado à criação de sistemas capazes de realizar tarefas que, quando executadas por humanos, exigiriam inteligência, como raciocínio, aprendizado e tomada de decisão. Esses sistemas processam grandes volumes de dados e extraem padrões complexos de forma automática, permitindo a construção de aplicações capazes de adaptar seu comportamento a novos contextos (Russell & Norvig, 2021; Goodfellow, Bengio & Courville, 2016). No contexto de classificação automática de textos, o subcampo do Aprendizado de Máquina (*Machine Learning*), que permite que computadores e máquinas imitem a maneira como os seres humanos aprendem, provê os métodos para que algoritmos aprendam padrões a partir de dados rotulados e generalizem decisões para novos exemplos (WANG et al., 2023). Souza e Filho (2021) destacam que abordagens supervisionadas têm sido amplamente aplicadas à análise de sentimentos, por possibilitarem a identificação automática de polaridades (positivas, negativas ou neutras) a partir de bases de comentários rotulados.

Apesar dos avanços significativos no campo do aprendizado de máquina, observa-se que grande parte dos estudos em análise de sentimentos permanece concentrada em contextos genéricos e em língua inglesa. Ainda há uma lacuna na aplicação de modelos supervisionados a dados em português e, especialmente, a interações digitais relacionadas à saúde mental. O presente trabalho busca contribuir nesse sentido, aplicando técnicas de aprendizado supervisionado a dados reais do YouTube, voltados a conteúdos de saúde e bem-estar.

2.2) Processamento de Linguagem Natural (NLP)

O Processamento de Linguagem Natural (Natural Language Processing (NLP)) é uma subárea da Inteligência Artificial dedicada a permitir que máquinas compreendam, processem e analisem a linguagem humana (Jurafsky & Martin, 2023). O NLP combina linguística

computacional com técnicas estatísticas e redes neurais, modelos inspirados no cérebro humano que aprendem padrões a partir de dados, possibilitando a extração de significados e a análise semântica de textos (Goodfellow, Bengio & Courville, 2016). Segundo Souza e Filho (2021), essa área é central para o desenvolvimento de sistemas de análise de sentimentos, uma vez que lida diretamente com a extração de significados e emoções em textos curtos e informais, como comentários em redes sociais e plataformas de vídeo.

No contexto deste trabalho, o NLP representa o elo entre a comunicação humana e os algoritmos de aprendizado de máquina. É a partir do processamento linguístico que se torna possível quantificar e interpretar o impacto emocional que os vídeos sobre saúde mental exercem sobre a comunidade que os assiste, objetivo central deste projeto.

Embora o NLP tenha alcançado avanços expressivos, os estudos ainda se concentram em ambientes formais de linguagem, com dados estruturados e padronizados. Falta, portanto, uma investigação mais profunda sobre a aplicação dessas técnicas em contextos de linguagem informal, como comentários do YouTube, que refletem o comportamento emocional espontâneo dos usuários. Este trabalho busca suprir essa lacuna ao empregar NLP na análise de discursos informais e emocionais, oferecendo uma visão mais próxima da experiência social real dos usuários.

2.3) Representação Textual e Modelos de Classificação em NLP

O Processamento de Linguagem Natural (NLP) exige a transformação de textos em representações numéricas, de modo que possam ser interpretados por algoritmos de aprendizado de máquina. Essa representação é a base para a aplicação de modelos de classificação, que têm por objetivo atribuir rótulos ou categorias a novos textos com base em padrões aprendidos a partir de exemplos previamente rotulados. Em tarefas de análise de sentimentos, os classificadores aprendem a distinguir entre comentários de polaridade positiva ou negativa (LI; PENG et al., 2020; WANG et al., 2023).

Inicialmente, o NLP utilizava representações estatísticas, como o *TF-IDF* (*Term Frequency–Inverse Document Frequency*), que converte textos em vetores ponderados conforme a frequência e a relevância das palavras no corpus. Essa técnica se mostrou simples, eficiente e amplamente utilizada em tarefas supervisionadas. No estudo de Souza e Filho (2021), o *TF-IDF* foi empregado com diferentes classificadores e obteve resultados expressivos, especialmente quando combinado ao Light Gradient Boosting Machine (*LightGBM*) e à Regressão Logística. Os autores verificaram que o *LightGBM* apresentou o melhor desempenho geral em acurácia e F1-score, reforçando a utilidade dessas abordagens como baseline para tarefas de classificação de sentimentos em português.

Apesar de eficientes, métodos baseados apenas em frequência, como *TF-IDF*, não capturam o significado semântico das palavras nem suas relações contextuais. Para superar essas limitações, surgiram as representações distribuídas (*word embeddings*), que mapeiam palavras para vetores contínuos de alta dimensão, de forma que termos semanticamente semelhantes ocupem posições próximas no espaço vetorial (BOJANOWSKI et al., 2017; SOUZA; FILHO, 2021). Essas representações têm se mostrado especialmente eficazes em tarefas de análise de sentimentos em português, proporcionando modelos de aprendizado de máquina mais precisos e robustos (SOUZA; FILHO, 2021). Os modelos Word2Vec (MIKOLOV et al., 2013), GloVe

(PENNINGTON; SOCHER; MANNING, 2014) e FastText (BOJANOWSKI et al., 2017) marcaram essa evolução.

O avanço seguinte no NLP foi impulsionado pelo aprendizado profundo (*deep learning*), um subcampo da inteligência artificial que utiliza redes neurais com múltiplas camadas para aprender representações hierárquicas de dados complexos. Em vez de depender de vetores fixos ou de regras manuais, esses modelos extraem automaticamente características de alto nível a partir do texto, aproximando-se do modo como os humanos compreendem o contexto linguístico (LI; PENG; LI et al., 2020; SOUZA; FILHO, 2021).

Um marco dessa nova geração foi o *ULMFiT (Universal Language Model Fine-tuning for Text Classification)*, que introduziu o conceito de aprendizado por transferência (transfer learning) em NLP, ao permitir que modelos de linguagem pré-treinados fossem ajustados para tarefas específicas, alcançando o estado da arte à época (HOWARD; RUDER, 2018; SOUZA; FILHO, 2021).

Posteriormente, o surgimento do *BERT (Bidirectional Encoder Representations from Transformers)* redefiniu o campo. Proposto por Devlin et al. (2019), o *BERT* introduziu *embeddings* contextuais, nos quais a representação de cada palavra varia de acordo com o contexto em que aparece. Essa arquitetura baseada em transformadores bidirecionais permitiu uma compreensão mais profunda das relações semânticas, superando as limitações dos *embeddings* estáticos e estabelecendo um novo estado da arte em NLP (DEVLIN et al., 2019).

No contexto do português brasileiro, Souza (2020) desenvolveu o *BERTimbau*, o primeiro modelo *BERT* pré-treinado especificamente para a língua portuguesa, utilizando o *Brazilian Web as Corpus (brWaC)*, um grande conjunto de textos coletados da web. O autor apresentou duas versões, *BERTimbau Base* e *BERTimbau Large*, que superaram o desempenho do modelo multilíngue *BERT* em tarefas como inferência textual, similaridade semântica e reconhecimento de entidades nomeadas. Souza (2020) destacou que o uso de um vocabulário construído a partir de dados do português e o treinamento prolongado aumentam significativamente a sensibilidade do modelo às nuances linguísticas da língua.

Esses avanços consolidam o *BERTimbau* como a principal ferramenta para análise de sentimentos e emoções em português, integrando o poder do aprendizado profundo com uma modelagem linguística específica da realidade brasileira. Por essa razão, o presente trabalho fundamenta-se nessa abordagem moderna para avaliar o impacto emocional de vídeos sobre saúde e bem-estar, explorando a capacidade do modelo de compreender contextos e identificar padrões de reação do público.

Apesar do avanço de modelos como o *BERTimbau*, observa-se uma escassez de pesquisas que apliquem essas arquiteturas ao domínio específico da saúde mental e ao ambiente multimodal do YouTube. A literatura concentra-se em bases textuais padronizadas e contextos genéricos, sem avaliar o impacto emocional de conteúdos audiovisuais. O presente estudo busca preencher essa lacuna, aplicando técnicas modernas de NLP e *Deep Learning* à análise de sentimentos em comentários reais, contribuindo para a compreensão do impacto emocional do consumo de conteúdo digital no público brasileiro.

2.4) Análise de Sentimentos e Emoções em Plataformas Digitais

A aplicação prática de técnicas de análise de sentimentos em contextos digitais é de grande relevância para compreender a recepção de conteúdos na internet. Afonso e Duque (2019) analisaram comentários de vídeos do YouTube utilizando *SVM (Support Vector Machine)* com vetorização *TF-IDF* e demonstraram que a acurácia do modelo depende diretamente da uniformidade temática do corpus. Quando os comentários se referiam ao mesmo objeto (ou “entidade dominante”), o modelo alcançou 81% de acurácia e F1-score de 0,806, superando os experimentos mais amplos com múltiplos tópicos.

Os autores ressaltam que a linguagem informal, o uso de ironias e as variações linguísticas do português nas interações digitais representam desafios para a classificação automatizada de sentimentos. Esses achados reforçam a necessidade de modelos mais sensíveis ao contexto, como o *BERTimbau*, que é capaz de capturar nuances semânticas e emocionais. Assim, a utilização de técnicas avançadas de NLP, em especial os transformadores, é essencial para compreender o impacto emocional que determinados conteúdos audiovisuais exercem sobre o público.

Embora os trabalhos existentes demonstrem o potencial das técnicas de aprendizado supervisionado em comentários do YouTube, ainda são raros os estudos que associam a análise de sentimentos ao impacto psicológico dos conteúdos de saúde mental. Dessa forma, este trabalho diferencia-se por empregar técnicas de NLP avançadas em uma aplicação prática voltada à avaliação emocional da audiência, propondo uma abordagem inovadora que alia tecnologia e bem-estar digital.

2.5) NLP Aplicado à Saúde Mental e Bem-Estar

O uso de modelos de linguagem para compreender aspectos de saúde mental vem crescendo nos últimos anos. A análise de comentários em plataformas como o YouTube pode oferecer indicadores valiosos sobre o impacto psicológico e emocional dos conteúdos voltados ao bem-estar e à saúde. Ao aplicar técnicas de análise de sentimentos a esses dados, é possível identificar padrões de reação do público, revelando se os vídeos provocam percepções positivas, negativas ou neutras.

Essa abordagem se alinha ao que Souza e Filho (2021) apontam como tendência: a utilização de modelos de aprendizado de máquina para interpretar interações humanas em larga escala, auxiliando na construção de ferramentas de monitoramento social e emocional. A incorporação de modelos de última geração, como o *BERTimbau* (SOUZA, 2020), permite elevar o nível de precisão dessas análises, contribuindo para que os resultados sirvam como suporte à conscientização sobre o impacto emocional do consumo de conteúdo digital relacionado à saúde mental.

3. Metodologia

Nessa seção, é apresentado o desenvolvimento deste trabalho, descrevendo a metodologia que será utilizada para a execução dos experimentos.

A pesquisa será mista (quali-quantitativa). O aspecto quantitativo estará presente na mensuração das métricas de desempenho do modelo e na classificação das polaridades (positiva ou negativa) dos comentários. Já o aspecto qualitativo será evidenciado na interpretação

contextual dos resultados, por meio da análise manual e interpretativa de uma amostra representativa dos comentários classificados pelo modelo. Essa etapa buscará identificar padrões linguísticos e emocionais recorrentes, expressões de apoio, empatia ou sofrimento, bem como relações entre o tipo de conteúdo dos vídeos e as reações dos espectadores. A análise será guiada por categorias temáticas emergentes, que permitirão compreender de forma mais profunda o impacto emocional e social gerado pelos vídeos sobre saúde mental.

O esquema geral da metodologia é apresentado na Figura 1. Nas próximas subseções serão detalhados os itens da metodologia mostrada na Figura 1.




Figura 1: Metodologia utilizada no projeto

3.1 Coleta e Armazenamento dos Dados

A coleta de dados será realizada de forma automatizada, por meio de scripts em Python integrados à YouTube Data API v3, serviço oficial disponibilizado pelo Google que permite o acesso a informações públicas da plataforma. Essa API possibilita a extração de comentários, títulos, descrições e metadados de vídeos, assegurando a autenticidade e a legitimidade da base de dados.

Durante a coleta, serão filtrados os vídeos pertencentes a canais e playlists dedicados à saúde mental e bem-estar, com base em palavras-chave como “ansiedade”, “depressão”, “saúde mental”, “autocuidado”, “terapia” e “saúde emocional”. Serão extraídos os comentários e suas respectivas informações contextuais, como data e número de curtidas, a fim de enriquecer a análise posterior.

Os dados serão coletados de forma anonimizada, sem retenção de informações pessoais dos usuários, garantindo o cumprimento das normas éticas e de privacidade definidas pela plataforma e pela legislação vigente, como a Lei Geral de Proteção de Dados (LGPD).

Os dados coletados serão armazenados em formato CSV (Comma-Separated Values), preservando sua estrutura e facilitando o tratamento posterior. A base de dados resultante será composta por colunas representando o texto do comentário, informações de metadados e, posteriormente, os rótulos atribuídos pelo modelo de classificação.

3.2 Pré-processamento e limpeza dos dados

Após a coleta, os textos passarão por uma etapa de pré-processamento, fundamental para eliminar ruídos e padronizar o corpus linguístico. Essa fase visa garantir que o modelo de análise opere sobre dados consistentes e relevantes.

As principais operações realizadas serão:

- Remoção de URLs, emojis, hashtags e caracteres especiais;
- Conversão de todo o texto para letras minúsculas;
- Eliminação de stopwords (palavras sem carga semântica relevante);
- Tokenização, que divide o texto em unidades linguísticas;
- Lematização, que reduz palavras às suas formas canônicas.

Essas etapas serão implementadas com o auxílio das bibliotecas NLTK e re (expressões regulares), amplamente utilizadas em Processamento de Linguagem Natural (PLN). O resultado será um corpus limpo e padronizado, adequado para as fases posteriores de representação vetorial e modelagem supervisionada.

3.3 Transformação em representações numéricas

Concluída a limpeza textual, os comentários serão convertidos em representações numéricas utilizando o modelo *BERTimbau*, uma adaptação do *BERT* (*Bidirectional Encoder Representations from Transformers*) pré-treinada para o português.

O *BERTimbau* gera *embeddings* contextuais, isto é, vetores que representam cada texto levando em conta o significado das palavras em seu contexto. Esse tipo de representação supera abordagens tradicionais como *TF-IDF* ou *Word2Vec*, pois captura nuances semânticas e relações entre termos, mesmo quando usados em diferentes sentidos.

Cada comentário será, portanto, transformado em um vetor denso de alta dimensionalidade, que servirá como entrada para o modelo de classificação supervisionada na etapa seguinte.

3.4 Treinamento do modelo

Com as representações numéricas obtidas, será realizado o treinamento de um modelo supervisionado de classificação binária, cujo objetivo é identificar a polaridade dos comentários, positiva ou negativa.

Nesta etapa, serão testados diferentes algoritmos de classificação supervisionada com o objetivo de identificar aquele que apresentar melhor desempenho na tarefa de análise de sentimentos em língua portuguesa.

Entre os modelos a serem avaliados estão a Regressão Logística, Árvore de Decisão, Random Forest e XGBoost, amplamente utilizados na literatura em tarefas de classificação de texto e análise de sentimentos.

Cada modelo será treinado a partir das *embeddings* geradas pelo *BERTimbau*, que representam os comentários em um espaço vetorial denso e semanticamente rico.

Os resultados de desempenho, medidos por métricas como acurácia, precisão, *recall* e F1-score, serão comparados para determinar o modelo mais adequado ao contexto do estudo, equilibrando eficiência computacional e capacidade de generalização.

3.3 Análise dos Resultados

Os resultados obtidos serão analisados sob duas perspectivas complementares: quantitativa e qualitativa.

Na análise quantitativa, a avaliação do desempenho do classificador será feita com as seguintes métricas principais:

- Acurácia: proporção de previsões corretas sobre o total de exemplos:
$$\frac{TP + TN}{TP + TN + FP + FN}.$$
- Precisão (*Precision*): proporção de exemplos classificados como positivos que são realmente positivos: $\frac{TP}{TP + FP}.$
- Revocação (*Recall* / Sensibilidade): proporção de positivos reais que foram corretamente identificados: $\frac{TP}{TP + FN}.$
- F1-score: média harmônica entre precisão e *recall*, útil em classes desbalanceadas:
$$2 * \frac{Precisão * Recall}{Precisão + Recall}.$$
- Matriz de confusão: tabela 2×2 que apresenta TP, TN, FP e FN, permitindo análise detalhada dos tipos de erro do classificador.

Estas métricas serão obtidas através de validação cruzada k-fold (com k = 5 ou 10, a definir experimentalmente), de forma a estimar robustamente a capacidade de generalização do modelo. Além das médias das métricas, serão reportados intervalos de confiança (por exemplo, desvio padrão entre folds) para indicar variabilidade.

Já a análise qualitativa buscará interpretar o conteúdo dos comentários classificados, com o objetivo de compreender o sentido das reações do público diante dos vídeos.

Para isso, será realizada uma amostragem aleatória de comentários positivos e negativos, provenientes de diferentes tipos de vídeos sobre saúde mental.

Essa amostra será analisada por meio de *WordClouds* (nuvens de palavras), que são representações visuais que destacam os termos mais frequentes, e tabelas de frequência, permitindo identificar rapidamente padrões linguísticos e temáticos em cada polaridade.

Com base nessas observações, serão descritos os temas predominantes em cada polaridade, relacionando as emoções expressas com o tipo de conteúdo analisado.

Essa análise qualitativa permitirá complementar os resultados numéricos com uma compreensão mais contextualizada do comportamento emocional da audiência, evidenciando como os vídeos de saúde mental e bem-estar influenciam o público de forma positiva ou negativa.

Espera-se que a metodologia proposta contribua para o avanço de pesquisas sobre análise de sentimentos em língua portuguesa, além de oferecer subsídios práticos para criadores de conteúdo e pesquisadores interessados em mensurar o impacto emocional de produções digitais relacionadas à saúde mental.

4. Cronograma

Atividades	Fev	Mar	Abr	Mai	Jun
1 - Coleta de dados via YouTube Data API v3					
2 - Organização e limpeza dos dados coletados					
3 - Pré-Processamento dos Dados					
4 - Geração de embeddings					
5 - Treinamento do modelo de classificação supervisionada					
6 - Análise de resultados					
7 - Preenchimento do relatório					
8 - Revisão e Entrega Final					

1. Coleta de dados via YouTube Data API v3

Será realizada a ampliação da base de dados coletada da API, com filtros mais abrangentes e refinados. A coleta incluirá vídeos em português relacionados a temas de saúde mental e bem-estar, utilizando palavras-chave como “ansiedade”, “depressão”, “autocuidado” e “saúde emocional”. A extração incluirá comentários, datas, número de curtidas e metadados dos vídeos, de modo a formar um conjunto de dados representativo para análise.

2. Organização e limpeza dos dados coletados

Os dados obtidos serão organizados em planilhas CSV e estruturados em colunas específicas (comentário, autor anonimizado, data, número de curtidas, vídeo de origem). Será feita uma análise inicial de consistência e a remoção de duplicatas, garantindo que o corpus textual esteja padronizado e livre de ruídos para a etapa seguinte.

3. Pré-Processamento dos Dados

Esta etapa envolve o tratamento linguístico da base textual. Serão aplicadas técnicas de limpeza de ruído (remoção de URLs, emojis e caracteres especiais), normalização (minúsculas), eliminação de stopwords e tokenização. A lematização será empregada para reduzir as palavras às suas formas canônicas, aumentando a precisão semântica do modelo. O objetivo é preparar o texto para ser interpretado de forma eficiente pelos algoritmos de NLP.

4. Geração de embeddings

Os textos pré-processados serão transformados em representações vetoriais utilizando o modelo pré-treinado *BERTimbau*. Essa técnica gera *embeddings* contextuais capazes de captar o significado das palavras considerando o contexto da frase, permitindo que o modelo compreenda nuances linguísticas e emocionais dos comentários em português.

5. Treinamento do modelo de classificação supervisionada

Com base nos *embeddings* gerados, será treinado um modelo supervisionado de classificação de sentimentos, visando identificar a polaridade dos comentários (positiva ou negativa). Serão testados diferentes parâmetros e arquiteturas, e o desempenho será avaliado com base em conjuntos de treino e teste.

6. Análise de resultados

A análise quantitativa consistirá na interpretação dos resultados numéricos obtidos pelas métricas de desempenho. Já a análise qualitativa envolverá a observação de padrões linguísticos e emocionais, buscando identificar que tipos de vídeos geram reações predominantemente positivas ou negativas, e quais fatores linguísticos influenciam essas percepções.

7. Preenchimento do relatório

Preenchimento das sessões faltantes do relatório e revisão das sessões já preenchidas.

8. Revisão final e entrega do TCC II

A etapa final compreende a revisão completa do texto, ajustes técnicos e linguísticos, adequação às normas da ABNT e entrega da versão final.

5. Referências bibliográficas

AFONSO, A. R.; DUQUE, C. G. Análise de sentimentos em comentários de vídeos do YouTube utilizando aprendizagem de máquinas supervisionada. *Ciência da Informação*, Brasília, v. 48, 2019. Disponível em: <https://revista.ibict.br/ciinf/article/view/4315>

. Acesso em: 27 out. 2025.

BOJANOWSKI, Piotr; GRAVE, Edouard; JOULIN, Armand; MIKOLOV, Tomas. Enriching Word Vectors with Subword Information. 2016. Disponível em: <https://arxiv.org/abs/1607.04606>

. Acesso em: 07 ago. 2025.

DEVLIN, Jacob; CHANG, Ming-Wei; LEE, Kenton; TOUTANOVA, Kristina. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2019. Disponível em: <https://arxiv.org/pdf/1810.04805>



. Acesso em: 5 set. 2025.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. Cambridge: MIT Press, 2016.

HOWARD, Jeremy; RUDER, Sebastian. Universal Language Model Fine-tuning for Text Classification. 2018. Disponível em: <https://arxiv.org/abs/1801.06146>

. Acesso em: 01 out. 2025.

JURAFSKY, Daniel; MARTIN, James H. Speech and Language Processing. 3. ed. Upper Saddle River: Pearson, 2023.

LI, Qian; PENG, Hao; LI, Jianxin; et al. A survey on text classification: from shallow to deep learning. arXiv preprint, arXiv:2008.00364, 2021. Disponível em: <https://arxiv.org/abs/2008.00364>

. Acesso em: 14 set. 2025.

MIKOLOV, Tomas; CHEN, Kai; CORRADO, Greg; DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. 2013. Disponível em: <https://arxiv.org/abs/1301.3781>

. Acesso em: 22 set. 2025.

PENNINGTON, Jeffrey; SOCHER, Richard; MANNING, Christopher. GloVe: Global Vectors for Word Representation. In: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha: Association for Computational Linguistics, 2014. Disponível em: <https://aclanthology.org/D14-1162.pdf>

. Acesso em: 27 out. 2025.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Harlow: Pearson, 2021.

SOUZA, Fábio Capuano de. BERTimbau: pretrained BERT models for Brazilian Portuguese. Universidade de São Paulo, São Paulo, 2020. Disponível em: <https://repositorio.unicamp.br/acervo/detalhe/1161906>

. Acesso em: 5 out. 2025.

SOUZA, Frederico Dias; FILHO, João Baptista de Oliveira e Souza. Sentiment Analysis on Brazilian Portuguese User Reviews. arXiv preprint, arXiv:2112.05459, 2021. Disponível em: <https://arxiv.org/pdf/2112.05459>

. Acesso em: 30 set. 2025.

WANG, Ying; et al. A survey of sentiment analysis: approaches, datasets, and future research. Applied Sciences, [S.l.], v. 1, 2023. Disponível em: <https://www.mdpi.com/2076-3417/13/7/4550>

. Acesso em: 27 out. 2025.